

Hybridný retrieval s preloženými dotazmi a doménovo-špecifickým rerankerom pre vyhľadávanie vedeckých zdrojov implicitných tvrdení

Matej Budoš

Jakub Vojtek

Abstract

Pracujeme na úlohe **CheckThat! Lab at CLEF 2026 Task 1**: k príspevku na sociálnych sieťach v angličtine (EN), nemčine (DE) alebo francúzštine (FR), ktorý odkazuje na nejakú vedeckú prácu bez priameho odkazu, treba nájsť túto prácu v zbierke 10 000 publikácií. Hlavné problémy sú: iný slovník tweetu a vedeckého abstraktu, jazykový rozdiel pri DE/FR dotazoch voči EN abstraktom a to, že tweety sú krátke a informatívne chudobné. Navrhujeme dvojkrovú pipeline: (1) hybridný retrieval kombinujúci BM25 a doladený mnohojazyčný model E5-large cez vážené zlučovanie výsledkov z viacerých pohľadov (preklad, originálny dotaz, LLM preformulovanie), a (2) SciBERT reranker doladený na typických chybách systému. Výsledné MRR@5 je 0,6503 na dev sete a 0,5743 na test sete.

1 Úvod

Keď niekto napíše na sociálnych sieťach niečo ako „*štúdia ukazuje, že táto liečba funguje dvakrát lepšie...*“ bez odkazu na zdroj, je ťažké automaticky zistiť, o akej konkrétnej práci hovorí. Práve to je jadro tejto úlohy: systém dostane tweet a má ho spojiť so správnou publikáciou z fixného zoznamu 10 000 vedeckých prác.

Úloha CheckThat! Lab at CLEF 2026 Task 1 (Schellhammer et al., 2026) tento problém zadefinovala formálne: vstup je tweet v EN, DE alebo FR, výstup má byť správna publikácia. Hodnotí sa MRR@5 — teda ako vysoko v rebríčku top-5 sa nachádza správny výsledok.

Problém je náročný z troch strán. Tweety sú **kratke a neformálne** (200–220 znakov) — popisujú výsledky vlastnými slovami, nie odbornými termínmi. Pri **DE a FR tweetoch** hľadáme v anglických abstraktoch, čo komplikuje porovnávanie. A napokon, tweety **neuvádzajú žiadne identifikátory** (DOI, mená autorov), takže systém nemá na čom „chytiť“ jasnú zhodu.

Náš systém sa inšpiruje najúspešnejšími prístupmi z predošlého ročníka (Ashbaugh et al., 2025; Schreieder and Färber, 2025) a oproti nim pridáva: zlučovanie viacerých vyhľadávacích pohľadov vrátane LLM preformulovania, lepší tokenizér pre BM25 a jazykovo-špecifické modely pre každý jazyk zvlášť.

2 Súvisiace práce

Bi-encodery (Reimers and Gurevych, 2019) fungujú tak, že tweet aj dokument zakódujú do vektora a podobnosť merajú ich skalárnym súčinom — vďaka tomu sú rýchle. Karpukhin et al. (Karpukhin et al., 2020) ukázali, že tréning s ťažkými negatívnymi príkladmi (dokumenty, ktoré sú podobné, ale nie správne) výrazne zlepšuje tieto modely. BM25 (Robertson and Zaragoza, 2009) je klasická metóda na kľúčové slovo — stále funguje dobre, hlavne keď sa v tweete objaví presný termín z abstraktu. Reciprocal Rank Fusion (Cormack et al., 2009) je jednoduchý spôsob, ako skombinovať výsledky z viacerých vyhľadávacích bez zložitého ladenia váh. SciBERT (Beltagy et al., 2019) je jazykový model predtrénovaný na vedeckých článkoch, vhodný na porovnávanie tweetov s abstraktmi.

Tím AIRwaves (Ashbaugh et al., 2025) dosiahol MRR@5 = 0,6828 na CLEF 2025 kombináciou E5-large a SciBERT rerankera s BM25-mineovanými negatívami. Claim2Source (Schreieder and Färber, 2025) skúsili tweet najprv prepísať do vedeckého štýlu pomocou LLaMA 3.3 70B a až potom vyhľadávať. Naša práca oba prístupy rozširuje na trojjazyčný dataset CLEF 2026 a skúma, ako sa dajú tieto nápady skombinovať.

3 Dataset a experimentálny setup

Dáta. Dataset CT26_Task1 (Schellhammer et al., 2026) obsahuje tweety s implicitnou vedeckou citáciou a zbierku 10 000 publikácií (polia *title*, *ab-*

stract, venue, authors). Rozdelenie datasetu je zobrazené v Tabuľke 1.

Jazyk	Train	Dev	Test
EN	14 977	3 905	6 076
DE	1 460	386	876
FR	2 807	702	1 220
Celkom	19 244	4 993	8 172

Table 1: Počet dotazov podľa jazyka a splitu.

Charakteristiky dát. Abstrakty sú v priemere 1 614 znakov dlhé (niektoré až 10 000+). Tweety majú 200–220 znakov; väčšina (57–70 %) obsahuje čísla (percenta, p-hodnoty, intervaly), čo je pre vyhľadávanie užitočný signál. Časť tweetov (13–24 %) obsahuje priame citáty z abstraktov. EN tweety často spomínajú vedcov alebo časopisy cez @mention. FR tweety z datasetu občas obsahujú prekladové artefakty (*VOCID-19, de-detection*).

Prostredie. Experimenty sme robili lokálne na NVIDIA RTX 4070 Laptop (8,6 GB VRAM), tréningy modelov prebehli na Kaggle (T4 × 2).

Metriky. Hlavnou metrikou je MRR@5. Navyše sledujeme MRR@1 a Stage-1 MRR@5 (výsledky pred rerankerom), aby sme vedeli, koľko toho reranker reálne pridáva.

4 Metodika

Celý systém je zobrazený na Obrázku 1.




Figure 1: Schéma navrhovanej dvojkrokovej pipeline.

4.1 Predspracovanie a preklad

Tweety pred vyhľadávaním vyčistíme: odstránime anonymizované @mentions, hashtags (slovo zachováme), emojis, subscriptové znaky ($\text{CO}_2 \rightarrow \text{CO2}$) a neviditeľné znaky. DE a FR

tweety preložíme do angličtiny pomocou NLLB-200 (NLLB Team, 2022) — pred prekladom ešte odfiltrujeme jazykové artefakty, ktoré by model miatli.

Navyše pre každý tweet vygenerujeme pomocou Claude Haiku preformulovanie do formálneho vedeckého štýlu (LLM rewrite). Toto preformulovanie ale *nenahrádza* originálny tweet ako dotaz — doladený E5 bol trénovaný na pôvodných tweetoch a formálny text by mu bol cudzí. Rewrite sa používa iba ako *d'alší pohľad* s nižšou váhou.

4.2 Stage 1: hybridný retrieval

BM25. Kolekciu sme zaindexoali s GPT-2 BPE tokenizérom namiesto bežného SciBERT tokenizéra — ukázalo sa, že BPE lepšie rozkladá vedecké termíny a čísla, čo MRR@5 zlepšilo o 0,011. Tituly sú zaindexované s väčšou váhou ($\text{boost} \times 4$), rovnako číselné výrazy. Ak tweet obsahuje úvodzovky so slovami z abstraktu, tieto úseky dostanú extra váhu ako silný lexikálny signál. Pre každý dotaz generujeme dva BM25 pohľady: preložený dotaz a LLM rewrite.

Dense retrieval. Používame multilingual-e5-large (Wang et al., 2024) (560 M parametrov) doladený na trénovacích príkladoch z datasetu. Každý príklad má formát (tweet, správna práca, ťažký negatív) — negatívy sú vybrané samotným modelom plus jeden BM25-mineovaný negatív (Ashbaugh et al., 2025). Pre každý jazyk existuje separátny checkpoint. Pre DE a FR sa retrieval spúšťa dvakrát — raz s prekladom a raz s originálom — a oba rebríčky sa zlučia, čo zlepšuje pokrytie.

RRF fúzia. Výsledky BM25 (top-30) a dense retrieverov (top-100) sa zlučia váženou Reciprocal Rank Fusion (Cormack et al., 2009) s $k = 15$:

$$\text{RRF}(d) = \sum_{r \in R} w_r \cdot \frac{1}{k + \text{rank}_r(d)}, \quad (1)$$

kde R je množina všetkých pohľadov. Stage 1 vracia top-20 dokumentov.

4.3 Stage 2: SciBERT reranker

Top-20 kandidátov zo Stage 1 prejde cez SciBERT cross-encoder (Beltagy et al., 2019), ktorý vidí tweet aj abstrakt naraz a vie tak zachytiť jemnejšie súvislosti než bi-encoder. Model sme doladili na chybách Stage 1 z dev setu (4 negatívy na dotaz). Skúšali sme preradiť 3, 5 alebo 7 kandidátov —

najlepšie funguje 5; viac kandidátov pridáva horšie dokumenty a výsledky sa zhoršujú.

5 Výsledky a diskusia

Hlavné výsledky. Tabuľka 2 ukazuje výsledky finálneho systému na dev a slepom test sete.

Split	Lang	MRR@1	MRR@5	S1 MRR@5
Dev	DE	0,526	0,606	0,576
	FR	0,624	0,692	0,683
	EN	0,593	0,652	0,630
	Avg	—	0,650	0,630
Test	DE	0,437	0,520	0,531
	FR	0,530	0,603	0,621
	EN	0,534	0,600	0,584
	Avg	—	0,574	0,579

Table 2: Výsledky finálneho systému. S1 MRR@5 = Stage 1 bez rerankera.

Ablácia komponentov. Tabuľka 3 ukazuje, čo priniesol každý komponent — merané na vzorke 100 príkladov z dev setu.

Konfigurácia	MRR@5
Základný systém (SciBERT tokenizér)	0,6115
+ BM25 rewrite pohľad	0,6182
+ asymetrický retrieval budget	0,6187
+ GPT-2 BPE tokenizér	0,6230
+ BPE + asymetrický budget	0,6249
+ jazyk.-špec. dense modely	0,6279
+ dense rewrite pohľad (DE, FR)	0,6331
+ SciBERT reranker (fin.)	0,6503

Table 3: Ablácia komponentov na dev sete (avg EN+DE+FR).

Diskusia. Tri kroky pomohli najviac. **GPT-2 BPE tokenizér** pre BM25 priniesol +0,011 — rozkladá vedecké termíny a čísllice lepšie než SciBERT tokenizér a nevyhadzuje informatívne konce slov. **SciBERT reranker** s 5 kandidátmi dal najväčší skok (+0,017): pretože vidí tweet aj dokument naraz, vie si všimnúť veci, ktoré bi-encoder prehliadne. **Dense rewrite pohľad** (LLM preformulovanie ako pridaný pohľad s váhou 0,5) pomohol o +0,005 bez toho, aby narušil doladený E5 model.

Jazykovo-špecifické checkpointy prispeli +0,003 — DE profitovalo z iného modelu než FR/EN.

Na **slepom test sete** výsledky klesli o $\approx 0,07$ (dev 0,650 vs. test 0,574). Podobný pokles medzi dev a test bol zaznamenaný aj v práci AIRwaves (Ashbaugh et al., 2025). Zaujímavé je, že reranker na

test sete pomáha EN (+0,016), ale mierne škodí DE (−0,011) a FR (−0,018). Pravdepodobne je to tým, že reranker sme trénovali na dev chybách Stage 1, ktoré sa líšia od test distribúcie.

Čo nefungovalo. Keď sme LLM rewrite použili ako náhradu pôvodného tweetu namiesto pridaného pohľadu, výsledky sa zhoršili — doladený E5 mal tréning na originálnych tweetoch a formálny text mu bol cudzí. Pridanie nemeckého/francúzskeho originálu priamo do BM25 dotazu zaviedlo cudzojazyčné stop-slová a MRR@5 pre DE kleslo o 0,04. Pseudo-relevance feedback ani druhá iterácia hard negative mining nepomohli. Generické rerankery (*mmarco-mMiniLMv2*, *bge-reranker-v2-m3*) konzistentne výsledky zhoršili — sú trénované na webovom vyhľadávaní, nie na tweet-to-paper úlohe.

6 Záver

Ukázali sme, že kombinácia BM25 s GPT-2 BPE tokenizérom, doladeného bi-encodera E5-large a SciBERT rerankera dáva solídne výsledky na trojjazyčnej tweet-to-paper úlohe. Finálny systém dosiahol avg MRR@5 = 0,650 na dev sete a 0,574 na test sete, čo je blízko k výsledku AIRwaves (0,683 na jednojazyčnom CLEF 2025 datase).

Možné ďalšie kroky: použiť LLM preformulovania priamo v tréningových dátach bi-encodera (nie len ako pohľad pri vyhľadávaní), zlepšiť preklad pre DE (zostáva najslabší jazyk), vyskúšať syntetické tweet-like popisy k publikáciám a nastaviť prah rerankera zvlášť pre každý jazyk.

Obmedzenia

DE a FR majú výrazne menej tréningových príkladov (1 460 a 2 807) než EN (14 977), čo mohlo ovplyvniť kvalitu doladených modelov. Tréning E5-large prebehol na T4 GPU (16 GB), čo obmedzilo veľkosť batchu. Keďže správne odpovede pre test set nie sú zverejnené, nevieme presne kvantifikovať distribučný posun medzi dev a test. Výsledky tiež nedajú priamo porovnať s CLEF 2025 leaderboardom, keďže ide o iný dataset.

References

Cem Ashbaugh, Leon Baumgärtner, Tim Greß, Nikita Sidorov, and Daniel Werner. 2025. AIRwaves at CheckThat! 2025: Retrieving scientific sources for implicit claims on social media with dual encoders and neural re-ranking. In *Working Notes of CLEF 2025*.

- Iz Beltagy, Kyle Lo, and Arman Cohan. 2019. SciBERT: A pretrained language model for scientific text. *arXiv preprint arXiv:1903.10676*.
- Gordon V. Cormack, Charles L. A. Clarke, and Stefan Buettcher. 2009. Reciprocal rank fusion outperforms Condorcet and individual rank learning methods. In *Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval*, pages 758–759.
- Vladimir Karpukhin, Barlas Oğuz, Sewon Min, Patrick Lewis, Ledell Wu, Sergey Edunov, Danqi Chen, and Wen-tau Yih. 2020. Dense passage retrieval for open-domain question answering. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing*, pages 6769–6781.
- NLLB Team. 2022. No language left behind: Scaling human-centered machine translation. *arXiv preprint arXiv:2207.04672*.
- Nils Reimers and Iryna Gurevych. 2019. Sentence-BERT: Sentence embeddings using Siamese BERT-Networks. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*, pages 3982–3992.
- Stephen Robertson and Hugo Zaragoza. 2009. The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval*, 3(4):333–389.
- Sebastian Schellhammer and 1 others. 2026. Overview of the CheckThat! lab at CLEF 2026: Source retrieval for scientific web claims. In *Working Notes of CLEF 2026*.
- Thomas Schreieder and Michael Färber. 2025. Claim2source at CheckThat! 2025: Bridging the style gap between social media claims and scientific publications via LLM rewriting. In *Working Notes of CLEF 2025*.
- Liang Wang, Nan Yang, Xiaolong Huang, Linjun Yang, Rangan Majumder, and Furu Wei. 2024. Multilingual E5 text embeddings: A technical report. *arXiv preprint arXiv:2402.05672*.