

Hybridný retrieval s preloženými dotazmi a doménovo-spezifickým rerankerom pre vyhľadávanie vedeckých zdrojov implicitných tvrdení

Matej Budoš

Jakub Vojtek

Abstract

Pracujeme na úlohe **CheckThat! Lab at CLEF 2026 Task 1**: k príspevku na sociálnych sieťach v angličtine (EN), nemčine (DE) alebo francúzštine (FR), ktorý odkazuje na nejakú vedeckú prácu bez priameho odkazu, treba nájsť túto prácu v zbierke 10 000 publikácií. Hlavné problémy sú: iný slovník tweetu a vedeckého abstraktu, jazykový rozdiel pri DE/FR dotazoch voči EN abstraktom a to, že tweety sú krátke a informatívne chudobné. Navrhujeme dvojkrovovú pipeline: (1) hybridný retrieval kombinujúci BM25 a doladený mnohojazyčný model E5-large cez vážené zlučovanie výsledkov z viacerých pohľadov (preklad, originálny dotaz, LLM preformulovanie), a (2) SciBERT reranker doladený na typických chybách systému. Výsledné MRR@5 je 0,6503 na dev sete a 0,5743 na test sete.

1 Úvod

Keď je na sociálnych sieťach napísané niečo ako „štúdia ukazujú, že táto liečba funguje dvakrát lepšie...“ bez odkazu na zdroj, je ťažké automaticky zistiť, o akej konkrétnej práci sa hovorí. Práve to je jadro tejto úlohy: tweet je systému predložený a má byť spojený so správnou publikáciou z fixného zoznamu 10 000 vedeckých prác.

V rámci úlohy CheckThat! Lab at CLEF 2026 Task 1 (Schellhammer et al., 2026) bol tento problém formálne zadefinovaný nasledovne: vstupom je tweet v EN, DE alebo FR, výstupom má byť správna publikácia. Hodnotí sa MRR@5 — teda ako vysoko v rebríčku top-5 sa nachádza správny výsledok.

Problém je náročný z troch strán. Tweety sú **krátke a neformálne** (200–220 znakov) — výsledky sú v nich opísané vlastnými slovami, nie odbornými termínmi. Pri **DE a FR tweetoch** sa prehľadávajú anglické abstrakty, čo komplikuje porovnávanie. A napokon, tweety **neobsahujú žiadne identifikátory** (DOI, mená autorov), takže

systémom nemôže byť zachytená žiadna jasná zhoda.

Systém je inšpirovaný najúspešnejšími prístupmi z predošlého ročníka (Ashbaugh et al., 2025; Schreieder and Färber, 2025); oproti nim bolo pridané: zlučovanie viacerých vyhľadávacích pohľadov vrátane LLM preformulovania, lepší tokenizér pre BM25 a jazykovo-spezifické modely pre každý jazyk zvlášť.

2 Súvisiace práce

Na CLEF 2025 Task 4b (Schellhammer et al., 2026) bol riešený rovnaký problém pre anglický jednojazyčný dataset; úspešné prístupy z tohto ročníka tvorili základ prezentovaného systému.

AIRwaves (Ashbaugh et al., 2025). Systémom AIRwaves bolo dosiahnuté druhé miesto v rebríčku Task 4b. V prvej fáze bolo použité hybridné vyhľadávanie kombinujúce BM25 a bi-encoder na báze modelu E5-large; bi-encoder bol doladený pomocou in-batch negatív a dolovaných hard negatív. Dokumenty boli indexované s kombináciou názvu a abstraktu a chunked tokenizáciou. V druhej fáze boli kandidáti preusporiadaní SciBERT cross-encoderom predtrénovaným na vedeckých textoch. Dosiahnuté MRR@5 bolo 0,5025 (BM25 baseline), 0,6174 (Stage 1) a 0,6828 (Stage 2 s rerankerom).

Claim2Source (Schreieder and Färber, 2025). Za hlavnú výzvu bol identifikovaný doménový rozdiel medzi neformálnymi tweetmi a vedeckými publikáciami. Ako riešenie bol navrhnutý transfer štýlu: tweet bol pred vyhľadávaním prepísaný do formálneho vedeckého štýlu pomocou LLM (LLaMA 3.3 70B). Bolo otestovaných 15 systémov (1 sparse, 7 dense, 7 hybridných). Najlepšie výsledky boli dosiahnuté modelom GritLM-7B, ktorý bol robustný voči neformálnemu vstupu aj bez transferu štýlu. Hybridné systémy konzistentne prekonali čisto dense modely.

Spoločné vzory. Analýzou úspešných prístupov z CLEF 2025 (Ashbaugh et al., 2025; Schreieder and Färber, 2025) boli identifikované nasledujúce spoločné prvky: (1) dvojstupňová architektúra retriever + re-ranker bola použitá takmer všetkými úspešnými tímami; (2) bi-encodery na báze E5-large sa stali štandardom pre Stage 1; (3) vedecké cross-encodery (SciBERT) boli preferované pre finálne preusporiadanie; (4) hard negative mining bol identifikovaný ako kľúčový faktor kvality doladených modelov; (5) riešenie lexikálnej priepasti medzi tweetom a vedeckým textom (style gap) bolo nevyhnutné pre dosiahnutie dobrých výsledkov.

V tejto práci sú oba hlavné prístupy (Ashbaugh et al., 2025; Schreieder and Färber, 2025) rozšírené na trojjazyčný dataset CLEF 2026 a skúmané, ako môžu byť tieto nápady skombinované vrátane jazykovo-špecifických modelov, váženej RRF fúzie a LLM preformulovania ako ďalšieho pohľadu.

3 Dataset a experimentálny setup

Dáta. Dataset CT26_Task1 (Schellhammer et al., 2026) obsahuje tweety s implicitnou vedeckou citáciou a zbierku 10 000 publikácií (polia *title*, *abstract*, *venue*, *authors*). Rozdelenie datasetu je zobrazené v Tabuľke 1.

Jazyk	Train	Dev	Test
EN	14 977	3 905	6 076
DE	1 460	386	876
FR	2 807	702	1 220
Celkom	19 244	4 993	8 172

Table 1: Počet dotazov podľa jazyka a splitu.

Charakteristiky dát. Abstrakty sú v priemere 1 614 znakov dlhé (niektoré až 10 000+). Tweety majú 200–220 znakov; väčšina (57–70 %) obsahuje čísla (percenta, p-hodnoty, intervaly), čo je pre vyhľadávanie užitočný signál. Časť tweetov (13–24 %) obsahuje priame citáty z abstraktov. V EN tweetoch sú vedci alebo časopisy často spomínaní cez @mention. FR tweety z datasetu občas obsahujú prekladové artefakty (*VOCID-19*, *de-detection*).

Prostredie. Experimenty boli vykonané lokálne na NVIDIA RTX 4070 Laptop (8,6 GB VRAM), tréningy modelov prebehli na Kaggle (T4 × 2).

Metriky. Hlavnou metriku je MRR@5. Navyše sú sledované MRR@1 a Stage-1 MRR@5

(výsledky pred rerankerom), aby bolo zrejmé, koľko toho reranker reálne pridáva.

4 Metodika

Celý systém je zobrazený na Obrázku 1.




Figure 1: Schéma navrhovanej dvojkrokovej pipeline.

4.1 Predspracovanie a preklad

Tweety boli pred vyhľadávaním vyčistené: anonymizované @mentions, hashtags (slovo bolo zachované), emojis, subscriptové znaky ($\text{CO}_2 \rightarrow \text{CO2}$) a neviditeľné znaky boli odstránené. DE a FR tweety boli preložené do angličtiny pomocou NLLB-200 — pred prekladom boli ešte odfiltrované jazykové artefakty, ktoré by model miatli.

Navyše pre každý tweet bolo pomocou Claude Haiku vygenerované preformulovanie do formálneho vedeckého štýlu (LLM rewrite). Toto preformulovanie však *nenahrádza* originálny tweet ako dotaz — doladený E5 bol trénovaný na pôvodných tweetoch a formálny text by mu bol cudzí. Rewrite je používaný iba ako *ďalší pohľad* s nižšou váhou.

4.2 Stage 1: hybridný retrieval

BM25. Kolekcia bola zaindexovaná s GPT-2 BPE tokenizérom namiesto bežného SciBERT tokenizéra — ukázalo sa, že BPE lepšie rozkladá vedecké termíny a čísla, čo MRR@5 zlepšilo o 0,011. Tituly sú zaindexované s väčšou váhou ($\text{boost} \times 4$), rovnako číselné výrazy. Ak tweet obsahuje úvodzovky so slovami z abstraktu, tieto úseky dostanú extra váhu ako silný lexikálny signál. Pre každý dotaz boli vygenerované dva BM25 pohľady: preložený dotaz a LLM rewrite.

Dense retrieval. Bol použitý model multilingual-e5-large (560 M parametrov)

doladený na tréningových príkladoch z datasetu. Každý príklad má formát (tweet, správna práca, ťažký negatív) — negatívy boli vybrané samotným modelom plus jeden BM25-mineovaný negatív (Ashbaugh et al., 2025). Pre každý jazyk bol vytvorený separátny checkpoint. Pre DE a FR bol retrieval spustený dvakrát — raz s prekladom a raz s originálom — a oba rebríčky boli zlúčené, čo zlepšuje pokrytie.

RRF fúzia. Výsledky BM25 (top-30) a dense retrieverov (top-100) boli zlúčené váženou Reciprocal Rank Fusion s $k = 15$:

$$\text{RRF}(d) = \sum_{r \in R} w_r \cdot \frac{1}{k + \text{rank}_r(d)}, \quad (1)$$

kde R je množina všetkých pohľadov. Stage 1 vrátila top-20 dokumentov.

4.3 Stage 2: SciBERT reranker

Top-20 kandidátov zo Stage 1 prešlo cez SciBERT cross-encoder, ktorý vidí tweet aj abstrakt naraz a dokáže zachytiť jemnejšie súvislosti než bi-encoder. Model bol doladený na chybách Stage 1 z dev setu (4 negatívy na dotaz). Boli vyskúšané varianty preradenia 3, 5 alebo 7 kandidátov — najlepšie funguje 5; viac kandidátov pridáva horšie dokumenty a výsledky sa zhoršujú.

5 Výsledky a diskusia

Hlavné výsledky. V Tabuľke 2 sú zobrazené výsledky finálneho systému na dev a slepom test sete.

Split	Lang	MRR@1	MRR@5	S1 MRR@5
Dev	DE	0,526	0,606	0,576
	FR	0,624	0,692	0,683
	EN	0,593	0,652	0,630
	Avg	—	0,650	0,630
Test	DE	0,437	0,520	0,531
	FR	0,530	0,603	0,621
	EN	0,534	0,600	0,584
	Avg	—	0,574	0,579

Table 2: Výsledky finálneho systému. S1 MRR@5 = Stage 1 bez rerankera.

Ablácia komponentov. V Tabuľke 3 je zobrazené, čo priniesol každý komponent — merané na vzorke 100 príkladov z dev setu.

Diskusia. Tri kroky pomohli najviac. **GPT-2 BPE tokenizér** pre BM25 priniesol +0,011 —

Konfigurácia	MRR@5
Základný systém (SciBERT tokenizér)	0,6115
+ BM25 rewrite pohľad	0,6182
+ asymetrický retrieval budget	0,6187
+ GPT-2 BPE tokenizér	0,6230
+ BPE + asymetrický budget	0,6249
+ jazyk.-špec. dense modely	0,6279
+ dense rewrite pohľad (DE, FR)	0,6331
+ SciBERT reranker (fin.)	0,6503

Table 3: Ablácia komponentov na dev sete (avg EN+DE+FR).

vedecké termíny a číslice sú ním rozkladané lepšie než SciBERT tokenizérom a informatívne konce slov nie sú vyhadzované. **SciBERT reranker** s 5 kandidátmi dal najväčší skok (+0,017): pretože sú tweet aj dokument videné naraz, môžu byť zachytené jemnejšie veci, ktoré bi-encoder prehliadne. **Dense rewrite pohľad** (LLM preformulovanie ako pridaný pohľad s váhou 0,5) pomohol o +0,005 bez toho, aby bol narušený doladený E5 model.

Jazykovo-špecifické checkpointy prispeli +0,003 — DE profitovalo z iného modelu než FR/EN.

Na **slepom test sete** výsledky klesli o $\approx 0,07$ (dev 0,650 vs. test 0,574). Podobný pokles medzi dev a test bol zaznamenaný aj v práci AIRwaves (Ashbaugh et al., 2025). Zaujímavé je, že reranker na test sete pomáha EN (+0,016), ale mierne škodí DE (−0,011) a FR (−0,018). Pravdepodobne je to tým, že reranker bol trénovaný na dev chybách Stage 1, ktoré sa líšia od test distribúcie.

Čo nefungovalo. Keď bol LLM rewrite použitý ako náhrada pôvodného tweetu namiesto pridaného pohľadu, výsledky sa zhoršili — doladený E5 bol trénovaný na originálnych tweetoch a formálny text mu bol cudzí. Pridaním nemeckého/francúzskeho originálu priamo do BM25 dotazu boli zavedené cudzojazyčné stop-slová a MRR@5 pre DE kleslo o 0,04. Pseudo-relevance feedback ani druhá iterácia hard negative mining nepomohli. Generické rerankery (*mmarcoMiniLMv2*, *bge-reranker-v2-m3*) konzistentne výsledky zhoršili — sú trénované na webovom vyhľadávaní, nie na tweet-to-paper úlohe.

6 Záver

Bolo ukázané, že kombinácia BM25 s GPT-2 BPE tokenizérom, doladeného bi-encodera E5-large a SciBERT rerankera dáva solídne výsledky na tro-

jjazyčnej tweet-to-paper úlohe. Finálnym systémom bolo dosiahnuté avg MRR@5 = 0,650 na dev sete a 0,574 na test sete, čo je blízko k výsledku AIRwaves (0,683 na jednojazyčnom CLEF 2025 datasete).

Možné ďalšie kroky: LLM preformulovania by mohli byť použité priamo v tréningových dátach bi-encodera (nie len ako pohl'ad pri vyhľadávaní), preklad pre DE by mohol byť zlepšený (zostáva najslabší jazyk), mohli by byť vyskúšané syntetické tweet-like popisy k publikáciám a prah rerankera by mohol byť nastavený zvlášť pre každý jazyk.

Obmedzenia

DE a FR majú výrazne menej tréningových príkladov (1 460 a 2 807) než EN (14 977), čo mohlo ovplyvniť kvalitu doladených modelov. Tréning E5-large prebehol na T4 GPU (16 GB), čo obmedzilo veľkosť batchu. Keďže správne odpovede pre test set nie sú zverejnené, distribučný posun medzi dev a test nemohol byť presne kvantifikovaný. Výsledky tiež nedajú priamo porovnať s CLEF 2025 leaderboardom, keďže ide o iný dataset.

Použitie umelej inteligencie

Pri tvorbe tohto článku boli použité nástroje umelej inteligencie. Konkrétne bol Claude (Anthropic) využitý na pomoc pri písaní a úprave textu.

References

- Cem Ashbaugh, Leon Baumgärtner, Tim Greß, Nikita Sidorov, and Daniel Werner. 2025. AIRwaves at CheckThat! 2025: Retrieving scientific sources for implicit claims on social media with dual encoders and neural re-ranking. In *Working Notes of CLEF 2025*.
- Sebastian Schellhammer and 1 others. 2026. Overview of the CheckThat! lab at CLEF 2026: Source retrieval for scientific web claims. In *Working Notes of CLEF 2026*.
- Thomas Schreieder and Michael Färber. 2025. Claim2source at CheckThat! 2025: Bridging the style gap between social media claims and scientific publications via LLM rewriting. In *Working Notes of CLEF 2025*.