

Hybridný retrieval s preloženými dotazmi a doménovo-spezifickým rerankerom pre vyhľadávanie vedeckých zdrojov implicitných tvrdení

Matej Budoš

Jakub Vojtek

Abstract

Pracujeme na úlohe **CheckThat! Lab at CLEF 2026 Task 1**: k príspevku na sociálnych sieťach v angličtine (EN), nemčine (DE) alebo francúzštine (FR), ktorý odkazuje na nejakú vedeckú prácu bez priameho odkazu, treba nájsť túto prácu v zbierke 10 000 publikácií. Hlavné problémy sú: iný slovník tweetu a vedeckého abstraktu, jazykový rozdiel pri DE/FR dotazoch voči EN abstraktom a to, že tweety sú krátke a informatívne chudobné. Navrhujeme dvojkrovovú pipeline: (1) hybridný retrieval kombinujúci BM25 a doladený mnohojazyčný model E5-large cez vážené zlučovanie výsledkov z viacerých pohľadov (preklad, originálny dotaz, LLM preformulovanie), a (2) SciBERT reranker doladený na typických chybách systému. Výsledné MRR@5 je 0,6503 na dev sete a 0,5743 na test sete.

1 Úvod

Keď je na sociálnych sieťach napísané niečo ako „štúdia ukazujú, že táto liečba funguje dvakrát lepšie...“ bez odkazu na zdroj, je ťažké automaticky zistiť, o akej konkrétnej práci sa hovorí. Práve to je jadro tejto úlohy: tweet je systému predložený a má byť spojený so správnou publikáciou z fixného zoznamu 10 000 vedeckých prác.

V rámci úlohy CheckThat! Lab at CLEF 2026 Task 1 (Schellhammer et al., 2026) bol tento problém formálne zadefinovaný nasledovne: vstupom je tweet v EN, DE alebo FR, výstupom má byť správna publikácia. Hodnotí sa MRR@5 — teda ako vysoko v rebríčku top-5 sa nachádza správny výsledok.

Problém je náročný z troch strán. Tweety sú **krátke a neformálne** (200–220 znakov) — výsledky sú v nich opísané vlastnými slovami, nie odbornými termínmi. Pri **DE a FR tweetoch** sa prehľadávajú anglické abstrakty, čo komplikuje porovnávanie. A napokon, tweety **neobsahujú žiadne identifikátory** (DOI, mená autorov), takže

systémom nemôže byť zachytená žiadna jasná zhoda.

Systém je inšpirovaný najúspešnejšími prístupmi z predošlého ročníka (Ashbaugh et al., 2025; Schreieder and Färber, 2025); oproti nim bolo pridané: zlučovanie viacerých vyhľadávacích pohľadov vrátane LLM preformulovania, lepší tokenizér pre BM25 a jazykovo-spezifické modely pre každý jazyk zvlášť.

2 Súvisiace práce

Na CLEF 2025 Task 4b (Schellhammer et al., 2026) bol riešený rovnaký problém pre anglický jednojazyčný dataset; úspešné prístupy z tohto ročníka tvorili základ prezentovaného systému.

AIRwaves (Ashbaugh et al., 2025). Systémom AIRwaves bolo dosiahnuté druhé miesto v rebríčku Task 4b. V prvej fáze bolo použité hybridné vyhľadávanie kombinujúce BM25 a bi-encoder na báze modelu E5-large; bi-encoder bol doladený pomocou in-batch negatív a dolovaných hard negatív. Dokumenty boli indexované s kombináciou názvu a abstraktu a chunked tokenizáciou. V druhej fáze boli kandidáti preusporiadaní SciBERT cross-encoderom predtrénovaným na vedeckých textoch. Dosiahnuté MRR@5 bolo 0,5025 (BM25 baseline), 0,6174 (Stage 1) a 0,6828 (Stage 2 s rerankerom).

Claim2Source (Schreieder and Färber, 2025). Za hlavnú výzvu bol identifikovaný doménový rozdiel medzi neformálnymi tweetmi a vedeckými publikáciami. Ako riešenie bol navrhnutý transfer štýlu: tweet bol pred vyhľadávaním prepísaný do formálneho vedeckého štýlu pomocou LLM (LLaMA 3.3 70B). Bolo otestovaných 15 systémov (1 sparse, 7 dense, 7 hybridných). Najlepšie výsledky boli dosiahnuté modelom GritLM-7B, ktorý bol robustný voči neformálnemu vstupu aj bez transferu štýlu. Hybridné systémy konzistentne prekonali čisto dense modely.

Spoločné vzory. Analýzou úspešných prístupov z CLEF 2025 (Ashbaugh et al., 2025; Schreieder and Färber, 2025) boli identifikované nasledujúce spoločné prvky: (1) dvojstupňová architektúra retriever + re-ranker bola použitá takmer všetkými úspešnými tímami; (2) bi-encodery na báze E5-large sa stali štandardom pre Stage 1; (3) vedecké cross-encodery (SciBERT) boli preferované pre finálne preusporiadanie; (4) hard negative mining bol identifikovaný ako kľúčový faktor kvality doladených modelov; (5) riešenie lexikálnej priepasti medzi tweetom a vedeckým textom (style gap) bolo nevyhnutné pre dosiahnutie dobrých výsledkov.

V tejto práci sú oba hlavné prístupy (Ashbaugh et al., 2025; Schreieder and Färber, 2025) rozšírené na trojjazyčný dataset CLEF 2026 a skúmané, ako môžu byť tieto nápady skombinované vrátane jazykovo-špecifických modelov, váženej RRF fúzie a LLM preformulovania ako ďalšieho pohľadu.

3 Dataset a experimentálny setup

Dáta. Dataset CT26_Task1 (Schellhammer et al., 2026) obsahuje tweety s implicitnou vedeckou citáciou a zbierku 10 000 publikácií (polia *title*, *abstract*, *venue*, *authors*). Rozdelenie datasetu je zobrazené v Tabuľke 1.

Jazyk	Train	Dev	Test
EN	14 977	3 905	6 076
DE	1 460	386	876
FR	2 807	702	1 220
Celkom	19 244	4 993	8 172

Table 1: Počet dotazov podľa jazyka a splitu.

Charakteristiky dát. Abstrakty sú v priemere 1 614 znakov dlhé (niektoré až 10 000+). Tweety majú 200–220 znakov; väčšina (57–70 %) obsahuje čísla (percenta, p-hodnoty, intervaly), čo je pre vyhľadávanie užitočný signál. Časť tweetov (13–24 %) obsahuje priame citáty z abstraktov. V EN tweetoch sú vedci alebo časopisy často spomínaní cez @mention. FR tweety z datasetu občas obsahujú prekladové artefakty (*VOCID-19*, *de-detection*).

Prostredie. Experimenty boli vykonané lokálne na NVIDIA RTX 4070 Laptop (8,6 GB VRAM), tréningy modelov prebehli na Kaggle (T4 × 2).

Metriky. Hlavnou metriku je MRR@5. Navyše sú sledované MRR@1 a Stage-1 MRR@5

(výsledky pred rerankerom), aby bolo zrejmé, koľko toho reranker reálne pridáva.

4 Metodika

Celý systém je zobrazený na Obrázku 1.




Figure 1: Schéma navrhovanej dvojkrokovej pipeline.

4.1 Predspracovanie a preklad

Tweety boli pred vyhľadávaním vyčistené: anonymizované @mentions, hashtags (slovo bolo zachované), emojis, subscriptové znaky ($\text{CO}_2 \rightarrow \text{CO2}$) a neviditeľné znaky boli odstránené. DE a FR tweety boli preložené do angličtiny pomocou NLLB-200 (NLLB Team, 2022) — pred prekladom boli ešte odfiltrované jazykové artefakty, ktoré by model miatli.

Navyše pre každý tweet bolo pomocou Claude Haiku vygenerované preformulovanie do formálneho vedeckého štýlu (LLM rewrite). Toto preformulovanie však *nenahrádza* originálny tweet ako dotaz — doladený E5 bol trénovaný na pôvodných tweetoch a formálny text by mu bol cudzí. Rewrite je používaný iba ako *ďalší pohľad* s nižšou váhou.

4.2 Stage 1: hybridný retrieval

BM25. Kolekcia bola zaindexovaná s GPT-2 BPE tokenizérom namiesto bežného SciBERT tokenizéra — ukázalo sa, že BPE lepšie rozkladá vedecké termíny a čísla, čo MRR@5 zlepšilo o 0,011. Tituly sú zaindexované s väčšou váhou ($\text{boost} \times 4$), rovnako číselné výrazy. Ak tweet obsahuje úvodzovky so slovami z abstraktu, tieto úseky dostanú extra váhu ako silný lexikálny signál. Pre každý dotaz boli vygenerované dva BM25 pohľady: preložený dotaz a LLM rewrite.

Dense retrieval. Bol použitý model multilingual-e5-large (Wang et al., 2024)

(560 M parametrov) doladený na trénoch z datasetu. Každý príklad má formát (tweet, správna práca, ťažký negatív) — negatívy boli vybrané samotným modelom plus jeden BM25-mineovaný negatív (Ashbaugh et al., 2025). Pre každý jazyk bol vytvorený separátny checkpoint. Pre DE a FR bol retrieval spustený dvakrát — raz s prekladom a raz s originálom — a oba rebríčky boli zlúčené, čo zlepšuje pokrytie.

RRF fúzia. Výsledky BM25 (top-30) a dense retrieverov (top-100) boli zlúčené váženou Reciprocal Rank Fusion (Cormack et al., 2009) s $k = 15$:

$$\text{RRF}(d) = \sum_{r \in R} w_r \cdot \frac{1}{k + \text{rank}_r(d)}, \quad (1)$$

kde R je množina všetkých pohľadov. Stage 1 vrátila top-20 dokumentov.

4.3 Stage 2: SciBERT reranker

Top-20 kandidátov zo Stage 1 prešlo cez SciBERT cross-encoder (Beltagy et al., 2019), ktorý vidí tweet aj abstrakt naraz a dokáže zachytiť jemnejšie súvislosti než bi-encoder. Model bol doladený na chybách Stage 1 z dev setu (4 negatívy na dotaz). Boli vyskúšané varianty preradenia 3, 5 alebo 7 kandidátov — najlepšie funguje 5; viac kandidátov pridáva horšie dokumenty a výsledky sa zhoršujú.

5 Výsledky a diskusia

Hlavné výsledky. V Tabuľke 2 sú zobrazené výsledky finálneho systému na dev a slepom test sete.

Split	Lang	MRR@1	MRR@5	S1 MRR@5
Dev	DE	0,526	0,606	0,576
	FR	0,624	0,692	0,683
	EN	0,593	0,652	0,630
	Avg	—	0,650	0,630
Test	DE	0,437	0,520	0,531
	FR	0,530	0,603	0,621
	EN	0,534	0,600	0,584
	Avg	—	0,574	0,579

Table 2: Výsledky finálneho systému. S1 MRR@5 = Stage 1 bez rerankera.

Ablácia komponentov. V Tabuľke 3 je zobrazené, čo priniesol každý komponent — merané na vzorke 100 príkladov z dev setu.

Konfigurácia	MRR@5
Základný systém (SciBERT tokenizér)	0,6115
+ BM25 rewrite pohľad	0,6182
+ asymetrický retrieval budget	0,6187
+ GPT-2 BPE tokenizér	0,6230
+ BPE + asymetrický budget	0,6249
+ jazyk.-špec. dense modely	0,6279
+ dense rewrite pohľad (DE, FR)	0,6331
+ SciBERT reranker (fin.)	0,6503

Table 3: Ablácia komponentov na dev sete (avg EN+DE+FR).

Diskusia. Tri kroky pomohli najviac. **GPT-2 BPE tokenizér** pre BM25 priniesol +0,011 — vedecké termíny a číslce sú ním rozkladané lepšie než SciBERT tokenizérom a informatívne konce slov nie sú vyhadzované. **SciBERT reranker** s 5 kandidátmi dal najväčší skok (+0,017): pretože sú tweet aj dokument videné naraz, môžu byť zachytené jemnejšie veci, ktoré bi-encoder prehliadne. **Dense rewrite pohľad** (LLM preformulovanie ako pridaný pohľad s váhou 0,5) pomohol o +0,005 bez toho, aby bol narušený doladený E5 model.

Jazykovo-špecifické checkpointy prispeli +0,003 — DE profitovalo z iného modelu než FR/EN.

Na **slepom test sete** výsledky klesli o $\approx 0,07$ (dev 0,650 vs. test 0,574). Podobný pokles medzi dev a test bol zaznamenaný aj v práci AIRwaves (Ashbaugh et al., 2025). Zaujímavé je, že reranker na test sete pomáha EN (+0,016), ale mierne škodí DE (−0,011) a FR (−0,018). Pravdepodobne je to tým, že reranker bol trénovaný na dev chybách Stage 1, ktoré sa líšia od test distribúcie.

Čo nefungovalo. Keď bol LLM rewrite použitý ako *náhrada* pôvodného tweetu namiesto pridaného pohľadu, výsledky sa zhoršili — doladený E5 bol trénovaný na originálnych tweetoch a formálny text mu bol cudzí. Pridaním nemeckého/francúzskeho originálu priamo do BM25 dotazu boli zavedené cudzojazyčné stop-slová a MRR@5 pre DE kleslo o 0,04. Pseudo-relevance feedback ani druhá iterácia hard negative mining nepomohli. Generické rerankery (*mmarco-miniLMv2*, *bge-reranker-v2-m3*) konzistentne výsledky zhoršili — sú trénované na webovom vyhľadávaní, nie na tweet-to-paper úlohe.

6 Záver

Bolo ukázané, že kombinácia BM25 s GPT-2 BPE tokenizérom, doladeného bi-encodera E5-large a SciBERT rerankera dáva solídne výsledky na trojjazyčnej tweet-to-paper úlohe. Finálnym systémom bolo dosiahnuté avg MRR@5 = 0,650 na dev sete a 0,574 na test sete, čo je blízko k výsledku AIRwaves (0,683 na jednojazyčnom CLEF 2025 datasete).

Možné ďalšie kroky: LLM preformulovania by mohli byť použité priamo v tréningových dátach bi-encodera (nie len ako pohľad pri vyhľadávaní), preklad pre DE by mohol byť zlepšený (zostáva najslabší jazyk), mohli by byť vyskúšané syntetické tweet-like popisy k publikáciám a prah rerankera by mohol byť nastavený zvlášť pre každý jazyk.

Obmedzenia

DE a FR majú výrazne menej tréningových príkladov (1 460 a 2 807) než EN (14 977), čo mohlo ovplyvniť kvalitu doladených modelov. Tréning E5-large prebehol na T4 GPU (16 GB), čo obmedzilo veľkosť batchu. Keďže správne odpovede pre test set nie sú zverejnené, distribučný posun medzi dev a test nemohol byť presne kvantifikovaný. Výsledky tiež nedajú priamo porovnať s CLEF 2025 leaderboardom, keďže ide o iný dataset.

References

- Cem Ashbaugh, Leon Baumgärtner, Tim Greß, Nikita Sidorov, and Daniel Werner. 2025. AIRwaves at CheckThat! 2025: Retrieving scientific sources for implicit claims on social media with dual encoders and neural re-ranking. In *Working Notes of CLEF 2025*.
- Iz Beltagy, Kyle Lo, and Arman Cohan. 2019. SciBERT: A pretrained language model for scientific text. *arXiv preprint arXiv:1903.10676*.
- Gordon V. Cormack, Charles L. A. Clarke, and Stefan Buettcher. 2009. Reciprocal rank fusion outperforms Condorcet and individual rank learning methods. In *Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval*, pages 758–759.
- NLLB Team. 2022. No language left behind: Scaling human-centered machine translation. *arXiv preprint arXiv:2207.04672*.
- Sebastian Schellhammer and 1 others. 2026. Overview of the CheckThat! lab at CLEF 2026: Source retrieval for scientific web claims. In *Working Notes of CLEF 2026*.

Thomas Schreieder and Michael Färber. 2025. Claim2source at CheckThat! 2025: Bridging the style gap between social media claims and scientific publications via LLM rewriting. In *Working Notes of CLEF 2025*.

Liang Wang, Nan Yang, Xiaolong Huang, Linjun Yang, Rangan Majumder, and Furu Wei. 2024. Multilingual E5 text embeddings: A technical report. *arXiv preprint arXiv:2402.05672*.